Informe del proyecto: reconocimiento del alfabeto dactilológico de la Lengua de Señas Boliviana (LSB) con visión por computador

Documento de contexto para una IA que ayudará a redactar un artículo científico. Autor: estudiante de Ingeniería de Inteligencia Artificial (Bolivia). Fecha del informe: 17-10-2026. Todo lo que aparece aquí es lo realizado y decidido hasta ahora; lo que no se midió se indica como pendiente. Instrucción para la IA: no inventes resultados, cifras ni referencias que no estén en este documento; si falta un dato, pregúntalo o márcalo como pendiente.

1. Contexto y objetivo

El proyecto se llama "Visión por computador". La idea final del estudiante es un sistema de reconocimiento de lengua de señas asociado al idioma quechua. Se aclaró que el quechua es una lengua oral y no tiene señas propias: en Bolivia las personas sordas usan la Lengua de Señas Boliviana (LSB). Por eso el quechua se usa solo como etiqueta (nombre en quechua de cada seña) y se deja como trabajo futuro. La primera parte del proyecto es una demostración que lee señas con la cámara web usando Teachable Machine (TM) y que luego se llevó a un programa propio con interfaz gráfica.

Objetivo general: construir y evaluar un prototipo que reconozca en tiempo real, con cámara web, las letras estáticas del alfabeto dactilológico de la LSB. Objetivos específicos: (a) elegir la fuente oficial del alfabeto; (b) construir un conjunto de imágenes variado; (c) entrenar un clasificador de imágenes; (d) analizar qué letras se confunden; (e) desarrollar una interfaz de escritorio que muestre la letra detectada y forme texto.

2. Marco sobre la lengua de señas

Decisiones tomadas durante la investigación previa: se eligió la LSB (y no otra lengua de señas) como base del alfabeto. Se comparó con el alfabeto dactilológico peruano (imagen aportada por el estudiante) y se decidió usar el boliviano. La fuente oficial del alfabeto y de las palabras es el Módulo 1 del curso del Ministerio de Educación de Bolivia (alfabeto en las páginas 41 a 43; índice de palabras y señas con paginación propia, por ejemplo Saludos pág. 55, Familia pág. 59). Se mencionó que la LSB está reconocida legalmente (DS 328 de 2009 y una ley de 2025); estos datos legales se dijeron de memoria y deben verificarse antes de citarlos. El alfabeto dactilológico se usa para deletrear nombres y términos sin seña propia; la lengua de señas completa tiene su propio vocabulario y gramática, por lo que alfabeto y palabras son dos sistemas distintos.

Alcance técnico: un modelo de imagen de Teachable Machine clasifica un solo cuadro, así que solo sirve para señas de pose fija. Las letras con movimiento (por ejemplo CH, J, LL, Ñ, RR, Z), las palabras con movimiento y las oraciones quedan como trabajo futuro con seguimiento de manos (MediaPipe Hands, 21 puntos por mano) y modelos de secuencia (LSTM). Se elaboraron tres documentos de apoyo: qué señas son factibles de reconocer en TM, una lista de palabras de la LSB traducidas al quechua (preparada por la IA con conocimiento propio, no copiada de un diccionario, pendiente de validar con un hablante) y un paso a paso de la demo.

3. Primer modelo en Teachable Machine y diagnóstico

El estudiante entrenó un primer modelo con el alfabeto estático (24 letras: A, B, C, D, E, F, G, H, I, K, L, M, N, O, P, Q, R, S, T, U, V, W, X, Y, más la clase Sin letra o vacío). Parámetros por defecto de TM: 50 épocas, tamaño de lote 16, tasa de aprendizaje 0,001. El modelo detectaba, pero con dificultad y de forma inestable.

Se analizó el archivo de proyecto (.tm) y se encontró: casi todas las imágenes de cada clase eran cuadros casi idénticos tomados de un video corto (cerca del 100 % de duplicados aproximados); un solo fondo (un

mueble de madera); una sola persona; y el tamaño de la mano correlacionado con la clase. Esto induce al modelo a aprender atajos (fondo, tamaño, luz) en vez de la forma de la mano, y explica la mala generalización. TM entrena con recortes de 224 por 224 píxeles tomados del centro del cuadro, por lo que el encuadre al probar también importa.

4. Construcción del nuevo conjunto de datos

Como el estudiante no podía regrabar todo, se partió de sus fotos de la mano sobre una pantalla azul (croma) y se generaron variaciones. Pasos del proceso:

a) Segmentación de la mano: máscara por color de piel en espacio HSV combinada con "no es azul", cierre morfológico, componente conexa mayor, tratamiento de huecos (se rellenan solo los huecos que no dejan ver el fondo azul, para conservar el hueco de letras como O, C y F) y suavizado del contorno.

b) Corrección de color: el azul del fondo daba un tinte amarillento a la piel; se corrigió igualando los canales de crominancia a los de fotos de piel de referencia (espacio Lab, intensidad 0,5) y se atenuó el derrame del azul en los bordes.

c) Reencuadre: se detecta por dónde entra el brazo al cuadro, se toma la región más lejana como mano y se elige una ventana cuadrada con márgenes mínimos del 8 % para no cortar dedos. Algunas imágenes se reducen anclando el brazo al borde del cuadro para simular la mano más lejos.

d) Fondos nuevos: se reemplazó el azul por fondos que simulan una pared (blanco y tonos claros, café o marrón, y negro) con textura, degradado y viñeteado. Se retiraron fondos donde aparecía la cara del estudiante para evitar un atajo. Se conservó una parte de las fotos reales sobre azul.

e) Selección de fuentes: se descartaron las fotos más borrosas (varianza del laplaciano), se eligieron fotos distintas entre sí por muestreo del punto más lejano sobre miniaturas de 16 por 16 y se exigió un tamaño mínimo de palma (medida como el doble de la distancia máxima de la transformada de distancia, dividido por 224). Solo se usaron manos de tamaño mediano y grande porque las pequeñas dificultaban distinguir las letras.

f) Mejora de nitidez: ecualización local de contraste (CLAHE parcial) y enfoque leve solo sobre la mano, remuestreo Lanczos, sin halo en el contorno; variación aleatoria de brillo y volteo horizontal en una parte de las imágenes.

Problema de equilibrio: al subir mucho las imágenes de la letra E (670) y de otras letras parecidas, la E pasó a pesar más que las demás y el modelo tendía a responder E. El estudiante lo notó y se igualaron todas las clases. Versión final del conjunto: 24 letras con 300 imágenes cada una (60 reales sobre azul con color corregido, y 80 por cada fondo blanco, café y negro) más la clase Sin letra o vacío con 210 imágenes propias del estudiante, sin modificar. Total: 7.410 imágenes. Las letras muy parecidas (E, A, S, K, M, N, O, C, P, T) usan manos más grandes y más cercanas y se descartó una proporción menor de fotos borrosas. Se iteró con revisión visual de hojas de muestra y se corrigieron errores: dedos cortados por el encuadre, bordes escalonados, parches oscuros en la base del brazo, huecos mal rellenados, brazo flotante al reducir y fondos con aspecto de cortina.

Letras que el estudiante reportó como difíciles de reconocer: K, M, N, O, C, P, T y, después, la E (confundida con muchas). La causa probable es que son puños o manos curvas casi iguales (M, N, T, A, S, E; K y P; O y C), sumado a la diferencia entre imágenes sintéticas y las de la cámara real.

5. Modelo final y resultados disponibles

El estudiante entrenó el modelo en TM con el conjunto final y exportó Keras (keras_model.h5 y labels.txt; 25 clases). Se comprobó que carga en TensorFlow con Keras 2 (paquete tf-keras) porque falla en Keras 3.

Evaluación rápida hecha por la IA con 15 imágenes por letra elegidas al azar (360 en total): 87 % de aciertos (312 de 360) en fotos originales sobre fondo azul; los errores más frecuentes fueron P predicha como Q (6 casos), R como U (4), R como V (4), H como G (3), W como V (3), C como Q (2), C como M (2) y H como F (2). En las imágenes sintéticas el acierto fue 100 % (360 de 360). Advertencia metodológica obligatoria: ambas muestras pertenecen al conjunto de entrenamiento, por lo que son cifras optimistas y no miden generalización. TM también ofrece precisión por clase y matriz de confusión en su sección de detalles avanzados, pero esos valores no se han recogido todavía.

En una prueba de interfaz con una foto original de la letra M (del conjunto de entrenamiento), el modelo respondió S con 52 % y M con 19 %, lo que ilustra la confusión entre puños. Todavía no hay evaluación con cámara real, con personas que no grabaron muestras, ni con el fondo de la sala de la universidad. Esa evaluación es el resultado principal que falta para el artículo (propuesta: 10 intentos por letra por persona, con varias personas, y matriz de confusión).

6. Software desarrollado

Se desarrolló una prueba en Python con OpenCV (cámara, recorte central de 224 por 224, entrada en rango de menos 1 a 1 igual que TM) y una aplicación de escritorio. El modelo se convirtió de Keras a ONNX y se verificó equivalencia numérica (diferencia máxima de 3,6 por 10 a la menos 7 sobre 10 imágenes). La interfaz usa PySide6 y onnxruntime: video con marco guía, letra detectada con anillo de confianza, tres mejores candidatas con porcentaje, umbral de confianza ajustable (80 % por defecto), suavizado temporal de las probabilidades, escritura automática de una letra tras unos 12 cuadros estables y botones de espacio, borrar y limpiar. Se entregó un script para crear el ejecutable de Windows con PyInstaller; el ejecutable aún no fue generado ni probado con cámara real.

7. Limitaciones

Un solo sujeto (una mano) en las fotos base; imágenes mayormente sintéticas (fondos y color artificiales) con brecha entre datos de entrenamiento y cámara real; letras casi idénticas como puños; solo señas estáticas; no hay evaluación con datos independientes; las traducciones al quechua no están validadas por un hablante; los datos legales sobre la LSB deben verificarse; la clase Sin letra incluye unas 40 imágenes con rayas que podrían eliminarse; TM es una caja negra con pocos hiperparámetros ajustables.

8. Trabajo futuro

Grabar 40 a 50 fotos reales por letra en el entorno de la demo, con varias personas y manos derecha e izquierda; evaluar con personas externas y reportar matriz de confusión; clasificar con puntos de referencia de la mano (MediaPipe Hands) en lugar de píxeles, que es más robusto al fondo y base para movimiento; añadir señas con movimiento y oraciones con una red de secuencias (LSTM); validar las señas con la Federación Boliviana de Sordos o intérpretes; asociar etiquetas en quechua.

9. Requisitos de la revista (plantilla adjunta, Revista 3i)

La plantilla pide: artículo científico de 6 a 12 páginas, interlineado 1,5, sin sangrías (salvo sangría francesa en referencias); título de máximo 12 palabras y su traducción al inglés y al portugués; resumen de máximo 200 palabras en un solo párrafo que integre objetivo, método, resultados y conclusión, sin citas, y su versión en inglés (Abstract) y portugués (Resumo); de 3 a 5 palabras clave en minúsculas, tomadas del Tesauro de la UNESCO y presentes en el título y el resumen. Secciones: Introducción (tema, justificación, objetivo; de lo general a lo particular; indicar si es resultado de tesis o monografía), Metodología (métodos y técnicas, muestra, sin conceptualizar ni justificar), Resultados (mínimo 3 páginas; tablas y figuras en formato editable, numeradas y citadas en el texto; en tiempo presente), Discusión (comparar con estudios similares, citar

fuentes primarias de revistas indexadas con DOI, similitud máxima de 25 %), Conclusiones (resumen de lo principal, sin pedir más información), Referencias (APA séptima edición, de 10 a 50, orden alfabético, con enlace o DOI, al menos 90 % con enlace), Agradecimientos (solo si hay financiamiento; se elimina si es tesis), Sobre el autor (4 o 5 líneas), Financiamiento, Declaración de intereses, Declaración de consentimiento informado y Derechos de uso (licencia Creative Commons Atribución 4.0). Se evitan viñetas y notas al pie y se usan párrafos de 6 a 10 líneas. Se evita lenguaje fuerte o calificativos. Al subir se envían tres documentos: manuscrito, carta de entendimiento y formulario de autoverificación.

10. Referencias usadas en el proyecto (formato APA 7; verificar enlaces antes de entregar)

A. Fuentes de contenido (lengua de señas y quechua), usadas durante el proyecto:

Ministerio de Educación de Bolivia, Federación Boliviana de Sordos, Fundación Amazónica para el Desarrollo de los Sordos y Proyecto "arca". (2010). Curso de enseñanza de la Lengua de Señas Boliviana LSB, Módulo 1. Ministerio de Educación. [Fuente oficial del alfabeto y de las palabras. El enlace exacto fue el que aportó el estudiante en el chat; hay que volver a copiarlo desde su navegador.]

Plaza Martínez, P. (2009). Qallarinapaq: Curso básico de quechua boliviano. [Sugerida como glosario para contrastar las traducciones al quechua; no fue consultada directamente por la IA. Completar editorial y enlace.]

Estado Plurinacional de Bolivia. (2009). Decreto Supremo N.º 328. [Mencionado de memoria como reconocimiento de la LSB; verificar número, fecha y texto antes de citar.] Estado Plurinacional de Bolivia. (2025). Ley N.º 1658. [Mencionada de memoria; verificar nombre, fecha y contenido antes de citar.]

Alfabeto dactilológico peruano. [Imagen aportada por el estudiante para comparar con el boliviano; no se registró la fuente. Si se usa en el artículo, identificar el documento original de Perú.]

B. Fuentes técnicas, conocidas por la IA de memoria (no se consultaron en línea durante esta sesión; verificar volumen, páginas, DOI y enlace antes de usarlas):

Carney, M., Webster, B., Alvarado, I., Phillips, K., Howell, N., Griffith, J., Jongejan, J., Pitaru, A., & Chen, A. (2020). Teachable Machine: Approachable web-based tool for exploring machine learning classification. Extended Abstracts of the 2020 CHI Conference on Human Factors in Computing Systems. https://doi.org/10.1145/3334480.3382839

Howard, A. G., Zhu, M., Chen, B., Kalenichenko, D., Wang, W., Weyand, T., Andreetto, M., & Adam, H. (2017). MobileNets: Efficient convolutional neural networks for mobile vision applications. arXiv. https://arxiv.org/abs/1704.04861 [Teachable Machine usa una red tipo MobileNet como base; confirmar la versión exacta en su documentación.]

Sandler, M., Howard, A., Zhu, M., Zhmoginov, A., & Chen, L.-C. (2018). MobileNetV2: Inverted residuals and linear bottlenecks. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. https://arxiv.org/abs/1801.04381

Zhang, F., Bazarevsky, V., Vakunov, A., Tkachenka, A., Sung, G., Chang, C.-L., & Grundmann, M. (2020). MediaPipe Hands: On-device real-time hand tracking. arXiv. https://arxiv.org/abs/2006.10214

Lugaresi, C., Tang, J., Nash, H., McClanahan, C., Uboweja, E., Hays, M., Zhang, F., Chang, C.-L., Yong, M. G., Lee, J., Chang, W.-T., Hua, W., Georg, M., & Grundmann, M. (2019). MediaPipe: A framework for building perception pipelines. arXiv. https://arxiv.org/abs/1906.08172

Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. Neural Computation, 9(8), 1735–1780. https://doi.org/10.1162/neco.1997.9.8.1735

Tobin, J., Fong, R., Ray, A., Schneider, J., Zaremba, W., & Abbeel, P. (2017). Domain randomization for transferring deep neural networks from simulation to the real world. IEEE/RSJ International Conference on Intelligent Robots and Systems. https://arxiv.org/abs/1703.06907 [Respalda la idea de variar fondos y apariencia para reducir la brecha entre datos sintéticos y reales.]

Bradski, G. (2000). The OpenCV library. Dr. Dobb's Journal of Software Tools. [Software de procesamiento de imagen usado.] ONNX. (s. f.). Open Neural Network Exchange. https://onnx.ai [Formato usado para el ejecutable; completar fecha de consulta.]

C. Recomendación para la IA: la plantilla exige fuentes primarias de revistas indexadas con DOI y de 10 a 50 referencias. Las referencias de la sección B son un punto de partida; hay que buscar además artículos científicos sobre reconocimiento de lengua de señas con visión por computador (por ejemplo alfabetos dactilológicos con redes convolucionales o MediaPipe), sobre lenguas de señas latinoamericanas y sobre la LSB y la comunidad sorda boliviana, y citarlos solo después de verificar que existen.

11. Qué se espera de la IA

Con este informe y la plantilla de la revista, redacta un borrador de artículo en español siguiendo exactamente las secciones y reglas de la plantilla. Propón un título de máximo 12 palabras y su traducción. Usa solo los datos de este documento; los resultados con cámara real están pendientes, así que deja marcadores claros donde faltan y no los inventes. Mantén un tono objetivo, sin calificativos fuertes, en tiempo presente en la sección de resultados, y presenta las cifras del apartado 5 con la advertencia de que se obtuvieron sobre datos de entrenamiento.